


Mapas Autoorganizados (SOM)



Alumno: Samuel David Pérez Brambila

Código: 222966286

Profesora: Karla Ávila Cárdenas

Sección: D01

Fecha de Entrega: 10 de Noviembre de 2024

Aprendizaje Máquina

Introducción a los mapas autoorganizados

En 1982 T. Kohonen presentó un modelo de red denominado mapas autoorganizados o SOM (Self-Organizing Maps), basado en ciertas evidencias descubiertas a nivel cerebral. Este tipo de red posee un aprendizaje no supervisado competitivo.




Introducción a los mapas autoorganizados

La red auto-organizada debe descubrir rasgos comunes, regularidades, correlaciones o categorías en los datos de entrada, e incorporarlos a su estructura interna de conexiones. Se dice, por tanto, que las neuronas deben auto-organizarse en función de los estímulos (datos) procedentes del exterior.

En el aprendizaje competitivo las neuronas compiten unas con otras con el fin de llevar a cabo una tarea dada. Se pretende que cuando se presente a la red un patrón de entrada, sólo una de las neuronas de salida (o un grupo de vecinas) se active.

Por tanto, las neuronas compiten por activarse, quedando finalmente una como neurona vencedora y anuladas el resto, que son forzadas a sus valores de respuesta mínimos.




Introducción a los mapas autoorganizados

La red auto-organizada debe descubrir rasgos comunes, regularidades, correlaciones o categorías en los datos de entrada, e incorporarlos a su estructura interna de conexiones. Se dice, por tanto, que las neuronas deben auto-organizarse en función de los estímulos (datos) procedentes del exterior.


En el aprendizaje competitivo las neuronas compiten unas con otras con el fin de llevar a cabo una tarea dada. Se pretende que cuando se presente a la red un patrón de entrada, sólo una de las neuronas de salida (o un grupo de vecinas) se active.

Por tanto, las neuronas compiten por activarse, quedando finalmente una como neurona vencedora y anuladas el resto, que son forzadas a sus valores de respuesta mínimos.



Introducción a los mapas autoorganizados


El objetivo de este aprendizaje es categorizar los datos que se introducen en la red. Se clasifican valores similares en la misma categoría y, por tanto, deben activar la misma neurona de salida. Las clases o categorías deben ser creadas por la propia red, puesto que se trata de un aprendizaje no supervisado, a través de las correlaciones entre los datos de entrada.



Fundamentos biológicos

Se ha observado que en el córtex de los animales superiores aparecen zonas donde las neuronas detectoras de rasgos se encuentran topológicamente ordenadas; de forma que las informaciones captadas del entorno a través de los órganos sensoriales se representan internamente en forma de mapas bidimensionales.

Aunque en gran medida esta organización neuronal está predeterminada genéticamente, es probable que parte de ella se origine mediante el aprendizaje. Esto sugiere, por tanto, que el cerebro podría poseer la capacidad inherente de formar mapas topológicos a partir de las informaciones recibidas del exterior.



Fundamentos biológicos


También se ha observado que la influencia que una neurona ejerce sobre las demás es función de la distancia entre ellas, siendo muy pequeña cuando están muy alejadas.

El modelo de red auto-organizado presentado por Kohonen pretende mimetizar de forma simplificada la capacidad del cerebro de formar mapas topológicos a partir de las señales recibidas del exterior.




¿Cómo trabajan los mapas autoorganizados?

La siguiente figura ilustra cómo formamos un mapa auto-organizado. La mancha púrpura es la distribución de los datos de entrenamiento. El pequeño disco blanco es el dato de entrenamiento actual extraído de esa distribución. Al principio, los nodos SOM se colocan arbitrariamente en el espacio de datos. Se selecciona el nodo (resaltado en amarillo) más cercano al datum de entrenamiento. Se mueve hacia el datum de entrenamiento, como lo hacen sus vecinos en la cuadrícula. Después de muchas iteraciones, la cuadrícula tiende a aproximarse a la distribución de los datos (derecha).



¿Cómo trabajan los mapas autoorganizados?

La distancia euclidiana a todos los vectores de peso se calcula cuando introducimos los datos de entrenamiento en la red. La neurona cuyo vector de peso es más similar a la entrada se llama la mejor unidad de coincidencia (BMU). Los pesos de la BMU y las neuronas cercanas a ella en la cuadrícula SOM se ajustan hacia el vector de entrada. Una vez que se ha determinado la BMU, el siguiente paso es calcular cuáles de los otros nodos están dentro del vecindario de la BMU.




Arquitectura del SOM

Un modelo SOM está compuesto por dos capas de neuronas.


- La **capa de entrada** (formada por N neuronas, una por cada variable de entrada) se encarga de recibir y transmitir a la capa de salida la información procedente del exterior.
- La **capa de salida** (formada por M neuronas) es la encargada de procesar la información y formar el mapa de rasgos.

Normalmente, las neuronas de la capa de salida se organizan en forma de mapa bidimensional como se muestra en la figura:





Arquitectura del SOM

Las conexiones entre las dos capas que forman la red son siempre hacia delante, es decir, la información se propaga desde la capa de entrada hacia la capa de salida. Cada neurona de entrada i está conectada con cada una de las neuronas de salida j mediante un peso w_{ji} . De esta forma, las neuronas de salida tienen asociado un vector de pesos W_j llamado vector de referencia (o codebook), debido a que constituye el vector prototipo (o promedio) de la categoría representada por la neurona de salida j . Así, el SOM define una proyección desde un espacio de datos en alta dimensión a un mapa bidimensional de neuronas.




Arquitectura del SOM

Entre las neuronas de la capa de salida, puede decirse que existen conexiones laterales de excitación e inhibición implícitas, pues aunque no estén conectadas, cada una de estas neuronas va a tener cierta influencia sobre sus vecinas. Esto se consigue a través de un proceso de competición entre las neuronas y de la aplicación de una función denominada de vecindad, que produce la topología o estructura del mapa. Las topologías más frecuentes son la rectangular y la hexagonal.



Arquitectura del SOM



Las neuronas adyacentes pertenecen a una vecindad N_j de la neurona j . La topología y el número de neuronas permanece fijo desde el principio. El número de neuronas determina la suavidad de la proyección, lo cual influye en el ajuste y capacidad de generalización del SOM.

Durante la fase de entrenamiento, el SOM forma una red elástica que se pliega dentro de la nube de datos originales. El algoritmo controla la red de modo que tiende a aproximar la densidad de los datos. Los vectores de referencia del codebook se acercan a las áreas donde la densidad de datos es alta. Eventualmente unos pocos vectores el codebook están en áreas donde existe baja densidad de datos.

El algoritmo del SOM

El proceso de aprendizaje del SOM es el siguiente:

1. Un vector x es seleccionado al azar del conjunto de datos y se calcula su distancia (similitud) a los vectores del codebook, usando, por ejemplo, la distancia euclídea:

$$\|x - m_c\| = \min_j \{\|x - m_j\|\}$$


2. Una vez que se ha encontrado el vector más próximo o BMU (best matching unit) el resto de vectores del codebook es actualizado. El BMU y sus vecinos (en sentido topológico) se mueven cerca del vector x en el espacio de datos. La magnitud de dicha atracción está regida por la tasa de aprendizaje. Mientras se va produciendo el proceso de actualización y nuevos vectores se asignan al mapa, la tasa de aprendizaje decrece gradualmente hacia cero. Junto con ella también decrece el radio de vecindad también. La regla de actualización para el vector de referencia dado i es la siguiente:

$$m_j(t+1) = \begin{cases} m_j(t) + \alpha(t)(x(t) - m_j(t)) & j \in N_c(t) \\ m_j(t) & j \notin N_c(t) \end{cases}$$

El algoritmo del SOM

Los pasos 1 y 2 se van repitiendo hasta que el entrenamiento termina. El número de pasos de entrenamiento se debe fijar antes a priori, para calcular la tasa de convergencia de la función de vecindad y de la tasa de aprendizaje.

Una vez terminado el entrenamiento, el mapa ha de ordenarse en sentido topológico: n vectores topológicamente próximos se aplican en n neuronas adyacentes o incluso en la misma neurona.



Medidas de calidad del mapa y precisión del mapa

Una vez que se ha entrenado el mapa, es importante saber si se ha adaptado adecuadamente a los datos de entrenamiento. Como medidas de calidad de los mapas se considera la precisión de la proyección y la preservación de la topología.

La medida de precisión de la proyección describe cómo se adaptan o responden las neuronas a los datos. Habitualmente, el número de datos es mayor que el número de neuronas y el error de precisión es siempre diferente de 0.

Para calcular la precisión de la proyección se usa el error medio de cuantificación sobre el conjunto completo de datos:

$$\varepsilon_q = \frac{1}{N} \sum_{i=1}^N \|x_i - m_c\|$$

Medidas de calidad del mapa y precisión del mapa

La medida de preservación de la topología describe la manera en la que el SOM preserva la topología del conjunto de datos. Esta medida considera la estructura del mapa. En un mapa que esté retorcido de manera extraña, el error topográfico es grande incluso si el error de precisión es pequeño. Una manera simple de calcular el error topográfico es:

$$\varepsilon_t = \frac{1}{N} \sum_{k=1}^N u(x_k)$$


donde $u(x_k)$ es igual a 1 si el primer y segundo BMUs de x_k no están próximos el uno al otro. De otro modo, $u(x_k)$ es igual a 0.



Visualización del SOM

El SOM es fácil de visualizar y, además, en los últimos años se han desarrollado diferentes técnicas de visualización, tanto para los vectores de referencia como para los histogramas de datos.

La **proyección de Sammon** representa el SOM de la manera gráfica que se muestra en la figura siguiente. Esta trata de encontrar una proyección no lineal óptima para los datos en alta dimensión, de manera que los vectores que se proyectan en la superficie bidimensional conservan la misma distancia euclídea relativa entre ellos que la que tenían en alta dimensión.



Visualización del SOM


La **matriz unificada de distancias**, o **matriz U**, es el método más popular para mostrar el SOM. Representa el mapa como una rejilla regular de neuronas, el tamaño y topología del mapa se puede observar en el gráfico donde cada elemento representa una neurona.

Cuando se genera la matriz U se calcula, a su vez, una matriz de distancias entre los vectores de referencia de neuronas adyacentes en el mapa bidimensional. Después se selecciona algún tipo de representación gráfica, por ejemplo, una escala de grises. Los colores en la figura se seleccionan de modo que cuanto más oscuro es el color entre dos neuronas, menor es la distancia entre ellas.



Visualización de histogramas de datos

Se trata de mostrar cómo los vectores de datos son clasificados por el SOM. El histograma de datos muestran cuántos vectores pertenecen a un cluster definido por cada neurona. El histograma se genera usando un SOM entrenado y el conjunto de datos.



Bibliografía

- Fritz. (2023, 21 de Septiembre). *Introduction to Self-Organizing Maps (SOMs)*. Fritz. Recuperado el 31 de Octubre de 2024 de: <https://fritz.ai/self-organizing-maps-som/?authuser=0>
- Jmmarin. (s.f.). *Los mapas auto-organizados de Kohonen (SOM)*. Universidad Carlos III de Madrid. Recuperado el 31 de Octubre de 2024 de: <https://halweb.uc3m.es/esp/Personal/personas/jmmarin/esp/DM/tema5dm.pdf>